Connecting Attacks and Testing report

FGSM 과 PGD 공격은 입력에 노이즈를 추가해서 모델이 잘못된 출력을 내도록 하는 것이고, DeepXplore 는 모델이 서로 다른 출력을 내는 입력을 찾도록 한다. 두 가지 모두 모델이 틀리게 행동하는 것과 관련이 있기 때문에 두 가지를 함께 사용하면 더 잘 찾을 수 있을지와 관련하여 네가지로 생각해보려고 한다.

우선 첫 번째로 시너지이다. 적대적 공격 방법으로 테스트를 할 때 쓰기 좋은 입력 데이터를 만들 수 있다. DeepXplore 는 랜덤으로 찾기 때문에 너무 넓고 경우의 수가 많아서 오래걸린다. 그렇기 때문에 PGD 공격과 같은 방법을 사용해서 Decision Boundary 근처에 있는 지점에서 시작하면 두 모델이 다른 예측을 하는 지점을 더 빨리 찾을 수 있다.

두 번째는 Coverage-guided Attacks 이다. 원래는 공격할 때 그냥 틀리게만 만들었었다. 이제 모델 안에서 아직 사용되지 않은 뉴런이 작동하도록 입력을 수정하면 모델의 더 다양한 부분을 테스트 할 수 있어서 더 다양한 문제를 발견할 수 있게 된다.

세번째는 효율성이다. 그냥 무작위로 테스트하면 많이 시도해야 버그가 나온다. 하지만 적대적 공격을 이용하면 문제가 생기는 데이터를 만들기 때문에 적은 횟수로도 중요한 버그를 빨리 찾을 수 있게 된다.

네번째는 한계점이다. 한계점으로는 너무 이상한 데이터가 만들어질 수 있다는 문제가 있다. 예를 들어서 사람이 봐도 완전히 깨진 이미지는 의미가 있는 노이즈라고 보기 어렵다. 이런 이미지로 모델이 틀렸다고 예측한다면 현실에서 실제로 일어날 수 있는 오류인지 생각하기 어렵다. 그래서 현실적이지 않고 비현실적인 테스트가 될 수 있다. 그렇기 때문에 조건을 걸어주는 것이 좋다. 예를 들어서 이미지인 경우에는 사람이 직접 눈으로 보아도 자연스러워야 한다. 그리고 자율주행이라면 실제 도로에서 가능한 상황이어야 한다.

위 내용을 정리해보면, 적대적 공격 방법은 문제가 있을 것으로 보이는 지점을 빠르게 찾고 DeepXplore 는 넓게 탐색해서 실제 문제를 본다. 그렇기 때문에 데이터를 정교하게 잘 바꾸는 적대적 공격을 넓게 탐색하는 DeepXplore 와 함께 사용하면 인공지능의 약점을 더 빠르고

효과적으로 찾아낼 수 있고 보완해 나갈 수 있다. 이 방법은 신뢰할 수 있는 인공지능 시스템을 만드는데 중요한 연구 방향이 될 것이다.